

# Relatório de CT-213

Henrique Fernandes Feitosa

## • Introdução

Nessa prática, buscou-se imitar a caminhada de um robô utilizando uma técnica chamada “imitation learning.” Para essa tarefa, foi criada uma rede neural assim como especificada na tabela 1.

**Tabela 1.** Arquitetura da rede neural usada para o imitation learning

Camada	Número de neurônios	Função de ativação
Dense	75	Leaky ReLU( $\alpha=0.01$ )
Dense	50	Leaky ReLU( $\alpha=0.01$ )
Dense	20	Linear


Para construir a rede neural, usou-se o framework tensorflow e o framework keras, que facilita o uso do tensorflow.

A partir dessas ferramentas, criou-se uma rede neural para estudar os efeitos da regularização e testou-a com as funções de classificação xor e sum\_gt\_zero. Para isso, variou-se o parâmetro de regularização para dois valores ,  $\lambda = 0$ (não tem regularização) e  $\lambda = 0.02$ .


Finalmente, criou-se rede neural apresentada na tabela 1 e a treinou com um dataset que continha o tempo e a posição das juntas do robô. Para a implementação, usou-se o erro quadrático como loss function, não usou-se regularização e todo o dataset foi usado em cada iteração.

## • Resultados e discussão

Inicialmente, testou-se os efeitos da regularização usando a função de ativação sun\_gt\_zero. Os resultados são mostrados nas figura 1(a) e 1(b).



(a) Função de custo para  $\lambda = 0$

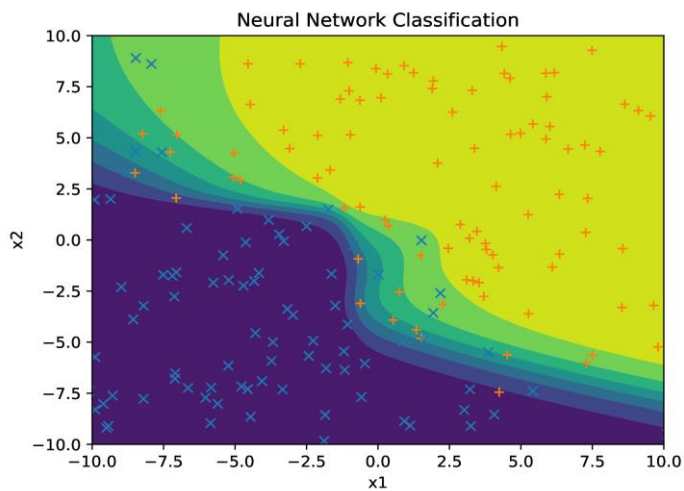


(b) Função de custo para  $\lambda = 0.02$


**Figur**

**a 2.** Mostra a função de custo para uma rede neural em que não possui regularização(a) e para outra que não possui(b).

Como o a função de custo convergiu para um valor maior no caso em que há regularização, pode-se concluir que está ocorrendo overfitting no caso em que não há regularização. Para comprovar isso, as figuras 3 e 4 mostram o dataset e o resultado da classificação.




(a) Resultado da classificação sem regularização




(b) Dataset para o caso sem regularização

**Figura 3.** Mostra o dataset e o resultado da classificação para o caso em que não há regularização



(a) Resultado da classificação com regularização




(b) Dataset para o caso com regularização


**Figura 4.** Mostra o dataset e o resultado da classificação para o caso em que não há regularização

Assim, percebe-se que no caso sem regularização a função tende a se adaptar perfeitamente ao dataset, o que não ocorre no caso com regularização. Isso é uma evidência muito forte que caracteriza o fenômeno de overfitting.

Para a função de classificação xor, a análise foi semelhante, os resultados se encontram nas figuras 5,6 e 7.




(a) Função de custo para  $\lambda = 0$




(b) Função de custo para  $\lambda = 0.02$

**Figura 5.** Mostra a função de custo para uma rede neural em que não possui regularização(a) e para outra que possui(b).




(a) Resultado da classificação sem regularização




(b) Dataset para o caso sem regularização

**Figura 6.** Mostra o dataset e o resultado da classificação para o caso em que não há regularização




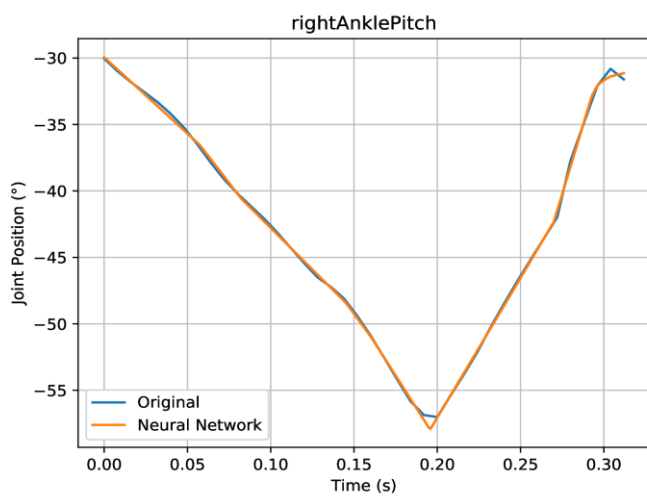
(a) Resultado da classificação com regularização





(b) Dataset para o caso com regularização

**Figura 7.** Mostra o dataset e o resultado da classificação para o caso em que não há regularização

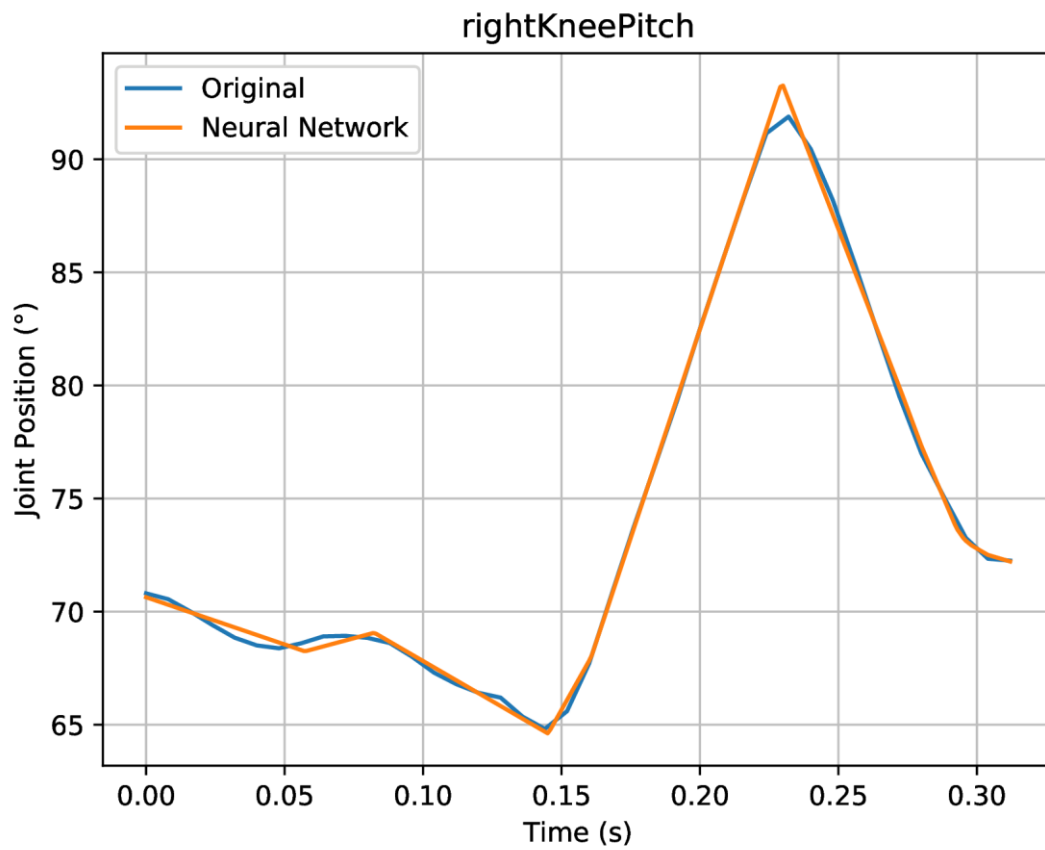
Por fim, os resultados do treinamento da rede neural especificada na tabela 1 estão nas figuras 8, 9 e 10.



**Figura 8.** Gráficos que mostram uma comparação entre as posições originais das juntas do robô e aquelas que foram aprendidas pela rede neural.



**Figura 9.** Gráficos que mostram uma comparação entre as posições originais das juntas do robô e aquelas que foram aprendidas pela rede neural.



**Figura 10.** Gráfico que mostra uma comparação entre as posições originais das juntas do robô e aquelas que foram aprendidas pela rede neural.

Analisando os gráficos, percebe-se que o resultado aprendido pela rede neural ficou bastante próximo do resultado original, o que é bastante satisfatório.